

Apêndice A

Otimização dos hiperparâmetros

A.1 *session-based, next-item*

skNN e vskNN

Em que k é a quantidade de vizinhos os quais a pontuação dos itens é calculada, N é o tamanho da amostra de sessões utilizadas para calcular os vizinhos mais próximos, Sim é a função de similaridade, W_{atual} é a função de decaimento que determina peso das ações individuais na sessão atual, $W_{candidato}$ é a função de decaimento que determina o peso dos itens candidatos de uma sessão vizinha e selecionados por itens clicados menos recentemente na sessão atual e IDF é o peso associado à frequência inversa do documento (*Inverse Document Frequency*).

Parâmetros			Métricas @10			
k	N	Sim	MRR	HR	Cov	Pop
50	500	Cosseno	0,172	0,571	0,645	0,204
50	500	Jaccard	0,165	0,534	0,534	0,289
1000	500	Jaccard	0,166	0,534	0,534	0,279
1500	500	Cosseno	0,160	0,511	0,529	0,283
100	2500	Cosseno	0,172	0,577	0,611	0,232

Tabela A.1: *session-based* kNN (sKNN)

Parâmetros					Métricas @10			
k	N	W_{atual}	$W_{candidato}$	IDF	MRR	HR	Cov	Pop
50	500	Linear	log	5	0,156	0,522	0,638	0,183
50	2500	Quadrático	Div	1	0,157	0,532	0,653	0,200
50	2500	N/A	Log	1	0,160	0,557	0,657	0,200
1500	2500	N/A	Div	10	0,146	0,507	0,580	0,242
1500	500	Quadrático	Log	N/A	0,142	0,489	0,524	0,282
1500	500	N/A	Linear	10	0,142	0,485	0,575	0,213

Tabela A.2: *Vector multiplication session-based* kNN (vsKNN)

Regras de sequência

Métricas são a quantidade de passos e a função de pesos.

Parâmetros		Métricas			
Passos	W	MRR@10	HR@10	Cov@10	Pop@10
6	Div	0.264	0,533	0.502	0.286
6	Log	0.255	0.519	0.490	0.293
6	Quadrático	0,270	0,533	0.516	0.275
11	Div	0.264	0.532	0.503	0.287
11	Linear	0.253	0.519	0.488	0.293
11	Log	0.254	0.516	0.490	0,296
12	Quadrático	0,270	0,533	0,517	0.275

Tabela A.3: Regras de sequência

STAN

$stan_1$ é o modelo com k igual a 2000, N igual a 2500, λ_{spw} igual a 3,62. $stan_2$ é o modelo com k igual a 100, N igual a 2500, λ_{spw} igual a 1,81.

Parâmetros					Métricas @10			
k	N	λ_{spw}	λ_{snh}	λ_{inh}	MRR	HR	Cov	Pop
2000	2500	3,62	100	7,24	0,202	0,637	0,217	0,277
200	1000	7,24	2,5	7,24	0,201	0,580	0,231	0,236
200	2500	7,24	100	1,81	0,190	0,637	0,238	0,217
500	1000	7,24	80	0,905	0,188	0,660	0,226	0,235
100	5000	10^{-5}	100	1,81	0,174	0,523	0,268	0,189
100	2500	1,81	40	3,62	0,197	0,627	0,245	0,202

Tabela A.4: stan

VSTAN

$vstan_1$ é o modelo com k igual a 1000 e N igual a 5000. $vstan_2$ é o modelo com k igual a 2000 e N igual a 1000.

smf

smf_1 é o modelo com função objetiva BPR e skip igual a 0,2. smf_2 é o modelo com função objetiva TOP1 com taxa de aprendizado igual a 0,05.

NARM

$NARM_1$ é o modelo com 100 unidades ocultas e taxa de aprendizado 0,006. $NARM_2$ é o modelo com 50 unidades ocultas e taxa de aprendizado 0,01.

Parâmetros								Métricas @10			
k	N	Sim	λ_{spw}	λ_{snh}	λ_{inh}	λ_{ipw}	λ_{IDF}	MRR	HR	Cov	Pop
1500	1000	Cosseno	10	5	10	5	False	0,198	0,439	0,601	0,237
1000	5000	Cosseno	10	40	5	10^{-5}	False	0,202	0,473	0,629	0,238
100	10000	Cosseno	2,5	100	2,5	2,5	False	0,194	0,456	0,629	0,196
2000	1000	Vetorial	10	100	0,625	1,25	False	0,187	0,447	0,644	0,252
1500	1000	Vetorial	5	100	5	5	False	0,187	0,445	0,639	0,213
1000	10000	Vetorial	10^{-5}	10	10	5	1	0,180	0,422	0,542	0,173

Tabela A.5: vstan

Parâmetros						Métricas @10			
Obj.	at.	d.	skip	m	l.r.	MRR	HR	Cov	Pop
BPR	Linear	0,3	0,2	0	0,01	0,359	0,614	0,183	0,269
BPR	Linear	0,3	0	0	0,01	0,358	0,610	0,191	0,267
TOP1	Linear	0,1	0,3	0,1	0,05	0,344	0,654	0,282	0,236
TOP1	Linear	0	0,3	0,8	0,004	0,350	0,644	0,196	0,273
BPR	Linear	0,3	0	0	0,07	0,319	0,627	0,306	0,231

Tabela A.6: smf

Parâmetros				Métricas @10			
Epochs	fatores	un. ocultas	lr	MRR	HR	Cov	Pop
20	50	100	0,006	0,197	0,392	0,340	0,203
20	50	100	0,005	0,195	0,392	0,330	0,205
20	50	50	0,01	0,176	0,365	0,363	0,192
20	100	50	0,002	0,155	0,342	0,344	0,182

Tabela A.7: NARM

GNN

otimização para GNN com *hidden size* igual a 100, *out size* igual a 100, *step* igual a 1, *nonhybrid* igual a True, *batch size* igual a 100, *n epoch* igual a 10, *batch predict* igual a True.

O modelo GNN₁ é o modelo com taxa de aprendizado igual a 0,004. O modelo GNN₂ é o modelo com taxa de aprendizado igual a 0,006.

Parâmetros				Métricas @10			
lr	l2	lr dc	lr dc step	MRR	HR	Cov	Pop
0,004	6×10^{-6}	0,366	5	0,437	0,713	0,308	0,231
0,006	3×10^{-6}	0,1	5	0,422	0,643	0,367	0,216
0,008	8×10^{-5}	0,455	3	0,410	0,648	0,360	0,206

Tabela A.8: GNN

NextItNet

*nextitnet*₁ é o modelo com taxa de aprendizado igual a 0,0007, *nextitnet*₂ é o modelo com taxa de aprendizado igual a 0,0009.

Parâmetros			Métricas @10			
lr	it.	neg.	MRR	HR	Cov	Pop
0,0007	30	True	0,308	0,561	0,227	0,299
0,0009	30	False	0,304	0,576	0,263	0,294
0,005	30	True	0,197	0,470	0,270	0,278
0,01	20	True	0,132	0,291	0,193	0,252

Tabela A.9: NextItNet

STAMP

n epochs igual a 30. O modelo STAMP₁ e STAMP₂ são o primeiro e segundo modelos na tabela.

Parâmetros		Métricas @10			
lr inicial	decay	MRR	HR	Cov	Pop
0,008	0,5	0,413	0,646	0,312	0,229
0,006	0	0,360	0,589	0,408	0,198

Tabela A.10: STAMP

GRU4Rec

Função de custo BPR max, função de ativação final ELU, *dropout* igual a 0,5, *momentum* igual a 0, *constrained embedding* igual a False.

Parâmetros		Métricas @10			
lr	dropout	MRR	HR	Cov	Pop
0,09	0,2	0,121	0,240	0,554	0,045
0,04	0,5	0,103	0,188	0,524	0,052

Tabela A.11: GRU4Rec

CSRM

Parâmetros				Métricas @10			
un. ocultas	<i>epochs</i>	lr	m.s.	MRR	HR	Cov	Pop
100	10	0,0008	256	0,167	0,319	0,328	0,151
100	10	0,0005	128	0,148	0,323	0,148	0,302

Tabela A.12: CSRM

A.2 *session-aware, next-item*

A otimização indica que o modelo com 5 passos na tabela A.13 retorna as melhores métricas. Ao realizar o *finetuning* para esse obtemos o modelo *usr* com *remind sessions number* igual a 8 W_{base} igual a 2 e W_{IRec} igual a 8.

Parâmetros			Métricas @10			
Passos	W	λ_{boost}	MRR	HR	Cov	Pop
5	Quadrático	3,9	0,330	0,556	0,729	0,186
7	Quadrático	1,7	0,326	0,553	0,735	0,187
2	Div	3,7	0,329	0,538	0,718	0,182

Tabela A.13: Regras de sequência

Modelos kNN

O modelo UVSTAN com k igual a 100, N igual a 2500, Sim igual a cosseno, λ_{spw} igual a 7,24, λ_{snh} igual a 80, λ_{inh} igual a 0,4525, λ_{ipw} igual a 0,4525, λ_{IDF} igual a 5, *extend session length* igual a 1, λ_{boost} igual a 2,1, *reminders* igual a True, *remind strategy* igual a hybrid, *remind sessions num* igual a 9, *weight base* igual a 2, *weight IRec* igual a 8 e *weight SSim* igual a 7.

O modelo VSKNN com k igual a 50, N igual a 500, Sim igual a cosseno, *weighting* igual a same, *weighting score* igual a linear, *idf weighting* igual a 2, *extend session length* igual a 11, λ_{boost} igual a 2,9.

O modelo USTAN com k igual a 200, N igual a 1000, λ_{spw} igual a 0,905, λ_{snh} igual a 100, λ_{inh} igual a 0,905, *extend session length* igual a 2, *boost own sessions* igual a 3,9, *reminders* igual a True, *remind strategy* igual a recency, *remind mode* igual a top, *remind sessions num* igual a 9 e *reminders num* igual a 3.

Modelos de redes neurais

Modelo IIRNN com *max epoch* igual a 100, *dropout pkeep* igual a 0,6, taxa de aprendizado igual a 0,006, *max session representation* igual a 15, *use last hidden state* igual a True e *embedding size* igual a 100.

Modelo NFCS com *window size* igual a 4, *max nb his sess* igual a 2 e *att alpha* igual a 1.

Parâmetros			Métricas @10			
r.s.n.	W_{base}	W_{IRec}	MRR	HR	Cov	Pop
8	2	8	0,362	0,625	0,732	0,339
10	1	9	0,360	0,607	0,751	0,333

Tabela A.14: *Finetuning* para o modelo de regras de sequência com 5 passos.

	Métricas @10			
Modelo	MRR	HR	Cov	Pop
UVSTAN	0,347	0,606	0,896	0,159
UVSKNN	0,319	0,624	0,844	0,184
USTAN	0,390	0,646	0,680	0,386

Tabela A.15: Modelos kNN

Modelo NSAR com *num epoch* igual a 20, *batch size* igual a 64, *keep pr* igual a 0,25, taxa de aprendizado igual a 0,005 e *hidden units* igual a 100.

Modelo UGRU4Rec com *loss* igual a top1-max, *final act* igual a linear, *dropout p hidden* igual a 0,1, *momentum* igual a 0,0, taxa de aprendizado igual a 0,03, *constrained embedding* igual a True e *extend session length* igual a 5.

Modelo HGRU4Rec com 100 camadas de sessões e 100 camadas de usuários, função de custo top1-max, função de ativação final tangente hiperbólica, *dropout p hidden usr* igual a 0,4, *dropout p hidden ses* igual a 0,2, *dropout p init* igual a 0,1, *momentum* igual a 0,2, taxa de aprendizado igual a 0,03, *user propagation mode* igual a all e *batch size* igual a 5.

Modelo SHAN com *iter* igual a 100, *global dimension* igual a 100, λ_{uv} igual a 0,0009 e λ_a igual a 10.

O modelo UNARM com *n epochs* igual a 20, *factors* igual a 100, *lr* igual a 0,008 e *extend session length* igual a 19. W_{base} igual a 1 e W_{IRec} igual a 2, *remind sessions num* igual a 5.

	Métricas @10			
Modelo	MRR	HR	Cov	Pop
IIRNN	0,368	0,591	0,813	0,190
NCFS	0,306	0,545	0,694	0,211
NSAR	0,285	0,513	0,683	0,197
UGRU4Rec	0,208	0,381	0,945	0,059
HGRU4Rec	0,194	0,319	0,912	0,061
SHAN	0,200	0,394	0,346	0,256
UNARM	0,348	0,560	0,796	0,298

Tabela A.16: Modelos de redes neurais

A.3 *session-based, remaining items*

A duração da otimização para cada modelo consta na tabela [A.17](#). Todas as otimizações foram realizadas com 40 iterações.

GNN	GRU4Rec	NARM	NextItNet	STAMP	SMF	sr	sKNN	vsKNN
2h07	2h47	8h57	1h28	0h26	3h28	0h01	0h04	0h03

Tabela A.17: Duração da otimização em horas e minutos para cada modelo.

GNN

GNN com *hidden size* igual a 100, *out size* igual a 100, *step* igual a 1, *nonhybrid* igual a True, *batch size* igual a 100, *n epoch* igual a 10, *batch predict* igual a True. Resultados na tabela [A.18](#). O modelo selecionado é o com NDCG@10 igual a 0,555.

Parâmetros				Métricas @10			
lr	l2	lr _{dc}	passo do lr _{dc}	MAP	NDCG	Cov	Pop
0,008	7×10^{-5}	0,455	5	0,093	0,548	0,300	0,239
0,005	6×10^{-6}	0,722	7	0,092	0,555	0,322	0,228
0,001	1×10^{-5}	0,366	7	0,080	0,508	0,378	0,218
0,007	9×10^{-6}	0,544	3	0,090	0,545	0,320	0,217

Tabela A.18: GNN

GRU4Rec

Os parâmetros da tabela são: função de custo, função de ativação final, *dropout*, *momentum*, *constrained embedding*, respectivamente. Resultados na tabela [A.19](#).

Parâmetros					Métricas @10			
custo	final	<i>dropout</i>	<i>momentum</i>	c.e.	MAP	NDCG	Cov	Pop
BPR	linear	0,2	0,0	True	0,024	0,176	0,530	0,049
TOP1	ELU	0,5	0,0	False	0,022	0,035	0,162	0,039
TOP1	ELU	0,5	0,3	True	0,010	0,075	0,614	0,018

Tabela A.19: GRU4Rec

NARM

Otimização com 20 epochs. Resultados na tabela [A.20](#).

NextItNet

As colunas de parâmetros são iterações, taxa de aprendizado e amostras negativas, respectivamente. Resultados na tabela [A.21](#).

skNN

Parâmetros são quantidade de k vizinhos, tamanho da amostra e função de similaridade, respectivamente. Resultados na tabela [A.22](#).

Parâmetros			Métricas @10			
fatores	unidades ocultas	lr	MAP	NDCG	Cov	Pop
100	100	0,004	0,041	0,275	0,332	0,210
100	100	0,008	0,040	0,276	0,354	0,188
50	100	0,003	0,035	0,242	0,357	0,193

Tabela A.20: NARM

Parâmetros			Métricas @10			
it.	lr	a.n.	MAP	NDCG	Cov	Pop
30	0,0008	True	0,069	0,428	0,236	0,293
20	0,008	True	0,043	0,243	0,282	0,287

Tabela A.21: NextItNet

smf

Parâmetros são função objetivo, função de ativação final, *dropout*, *skip*, *momentum* e taxa de aprendizado, respectivamente. Resultados na tabela [A.23](#).

Regras de sequência

Parâmetros são número de passos e o peso, respectivamente. Resultados na tabela [A.24](#).

STAMP

Parâmetros são número de épocas, taxa de decaimento e taxa de aprendizado inicial, respectivamente. Resultados na tabela [A.25](#).

vsKNN

Parâmetros são a quantidade de vizinhos k , tamanho da amostra, peso e peso na pontuação e peso idf.

Parâmetros			Métricas @10			
k	t.a.	sim.	MAP	NDCG	Cov	Pop
500	2500	Jaccard	0,090	0,407	0,229	0,246
50	5000	Cosseno	0,084	0,385	0,325	0,194

Tabela A.22: skNN

Parâmetros						Métricas @10			
f. obj.	f.at.	<i>dropout</i>	<i>skip</i>	<i>momentum</i>	l.r.	MAP	NDCG	Cov	Pop
TOP1	Linear	0,0	0,4	0,6	0,01	0,080	0,454	0,230	0,260
BPR	Linear	0,1	0,5	0,2	0,007	0,079	0,469	0,171	0,281

Tabela A.23: smf

Parâmetros		Métricas @10			
passos	W	MAP	NDCG	Cov	Pop
16	N/A, mesmo valor	0,085	0,466	0,219	0,282
6	Quadrático	0,075	0,444	0,241	0,263

Tabela A.24: Regras de sequência

Parâmetros			Métricas @10			
epochs	taxa de decaimento	l.r. inicial	MAP	NDCG	Cov	Pop
10	0,2	0,006	0,084	0,496	0,297	0,238
20	0,8	0,004	0,079	0,505	0,335	0,225
30	0,3	0,009	0,071	0,428	0,391	0,231

Tabela A.25: STAMP

Parâmetros					Métricas @10			
k	t.a.	W	W_{score}	W_{idf}	MAP	NDCG	Cov	Pop
100	500	N/A	Quadrático	False	0,090	0,412	0,231	0,245
50	2500	Log	Log	10	0,086	0,389	0,300	0,183

Tabela A.26: vsKNN

Parâmetros					Métricas @10			
k	t.a.	λ_{spw}	λ_{snh}	λ_{inh}	MAP	NDCG	Cov	Pop
500	1000	7,24	20	3,62	0,088	0,398	0,220	0,242
1500	2500	1,81	40	3,62	0,087	0,404	0,219	0,263

Tabela A.27: STAN

Parâmetros								Métricas @10			
k	t.a.	sim	λ_{spw}	λ_{snh}	λ_{inh}	λ_{ipw}	λ_{IDF}	MAP	NDCG	Cov	Pop
1500	10000	Cosseno	1,81	80	7,24	3,62	False	0,084	0,408	0,217	0,268
100	2500	Vetorial	3,62	80	0,905	0,905	10	0,078	0,356	0,323	0,156

Tabela A.28: VSTAN

Parâmetros				Métricas @10			
un. ocultas	epochs	l.r.	m.s.	MAP	NDCG	Cov	Pop
100	10	0,0009	256	0,036	0,256	0,300	0,210
100	10	0,0007	128	0,035	0,247	0,301	0,211

Tabela A.29: CSRM

A.4 *session-based, last item*

GNN	GRU4Rec	NARM	NextItNet	STAMP	SMF	sr	sKNN	vsKNN
2h05	2h47	9h01	1h37	0h28	3h21	0h01	0h01	0h01

Tabela A.30: Duração da otimização, em horas e minutos para cada modelo.

A seguir, otimizações para os modelos *session-based* com abordagem *last item*. Os parâmetros fixos são os mesmos para a otimização na abordagem *remaining items*.

Parâmetros				Métricas @10			
lr	l2	lr _{dc}	lr _{dc}	MRR	HR	Cov	Pop
0,005	6×10^{-6}	0,722	7	0,479	0,685	0,283	0,190
0,009	5×10^{-6}	0,455	3	0,413	0,630	0,295	0,195

Tabela A.31: GNN

Parâmetros						Métricas @10			
custo	final	<i>dropout</i>	<i>momentum</i>	c.e.	l.r.	MRR	HR	Cov	Pop
TOP1	Linear	0,3	0,0	True	0,1	0,187	0,285	0,430	0,043
TOP1	ELU	0,0	0,1	False	0,2	0,185	0,300	0,445	0,035

Tabela A.32: GRU4Rec

Parâmetros			Métricas @10			
fatores	unidades ocultas	lr	MRR	HR	Cov	Pop
100	100	0,003	0,245	0,430	0,261	0,206
50	100	0,008	0,198	0,455	0,280	0,185

Tabela A.33: NARM

Parâmetros			Métricas @10			
epochs	taxa de decaimento	l.r. inicial	MRR	HR	Cov	Pop
20	0,8	0,005	0,429	0,565	0,234	0,236
20	0,7	0,009	0,404	0,505	0,303	0,181

Tabela A.34: STAMP

Parâmetros			Métricas @10			
it.	lr	a.n.	MRR	HR	Cov	Pop
30	0,0006	True	0,314	0,555	0,193	0,260
30	0,001	True	0,305	0,610	0,305	0,192
30	0,005	True	0,236	0,510	0,235	0,245

Tabela A.35: NextItNet

Parâmetros			Métricas @10			
k	t.a.	sim.	MRR	HR	Cov	Pop
100	10000	Jaccard	0,263	0,720	0,243	0,198
50	1000	Jaccard	0,256	0,700	0,276	0,174

Tabela A.36: skNN

Parâmetros						Métricas @10			
f. obj.	f.at.	<i>dropout</i>	<i>skip</i>	<i>momentum</i>	l.r.	MRR	HR	Cov	Pop
TOP1	Linear	0,4	0,4	0,1	0,01	0,350	0,605	0,135	0,268
BPR	Linear	0,4	0,0	0,0	0,07	0,304	0,660	0,246	0,214
BPR	Linear	0,4	0,3	0,3	0,3	0,202	0,390	0,300	0,164

Tabela A.37: smf

Parâmetros		Métricas @10			
passos	W	MRR	HR	Cov	Pop
17	N/A	0,331	0,640	0,167	0,262
15	Quadrático	0,322	0,635	0,182	0,243
20	div	0,320	0,650	0,171	0,253

Tabela A.38: Regras de sequência

Parâmetros					Métricas @10			
k	t.a.	W	W_{score}	W_{idf}	MRR	HR	Cov	Pop
50	2500	Log	N/A	False	0,247	0,680	0,207	0,214
50	5000	N/A	Quadrático	10	0,228	0,680	0,246	0,165

Tabela A.39: vsKNN

Parâmetros					Métricas @10			
k	t.a.	λ_{spw}	λ_{snh}	λ_{inh}	MRR	HR	Cov	Pop
100	10000	3,62	80	7,24	0,195	0,549	0,530	0,189
100	10000	7,24	80	0,905	0,189	0,556	0,548	0,191

Tabela A.40: stan

Parâmetros								Métricas @10			
k	t.a.	sim	λ_{spw}	λ_{snh}	λ_{inh}	λ_{ipw}	λ_{IDF}	MRR	HR	Cov	Pop
1000	2500	vec	7,24	40	1,81	0,905	False	0,188	0,533	0,516	0,243
100	5000	coseno	1,81	100	7,24	0,905	1	0,177	0,501	0,583	0,151

Tabela A.41: vstan

Parâmetros				Métricas @10			
un. ocultas	<i>epochs</i>	l.r.	m.s.	MRR	HR	Cov	Pop
100	10	0,0009	256	0,214	0,395	0,281	0,143
100	10	0,001	256	0,175	0,405	0,274	0,134

Tabela A.42: CSRM